

# Matematica IV

**Autores:** Ortega Mariano, Daguerre Elgarte Ivy

**Código Auxiliar:** ■ Código Proyecto

## Parte 1: Predicción del valor de mercado

a) Recta de regresión para predecir el valor de mercado de un jugador a partir de la característica más relevante (a la que se destinará mayor proporción del presupuesto), respaldada por:

i) Prueba de significancia de regresión, coeficiente de determinación ( $R^2$ ) y correlación lineal ( $r$ ).

ii) Inferencias sobre los parámetros de la recta, estimando las fluctuaciones con una confianza del 95%.

iii) La proporción de veces que el valor de mercado supera la incertidumbre de predicción comparada con la respuesta media del valor de mercado para una característica fija, ambas con la misma confianza y ancho mínimo

i)

Para encontrar la recta que mejor se ajusta a los datos proporcionados permitiendo así predecir el valor de mercado de un jugador, utilizaremos regresión lineal simple. Queremos predecir el valor de mercado basándonos en una única característica clave, aquella a la que destinamos la mayor parte del presupuesto.

Teniendo un punto  $(x_i, y_i)$  la distancia vertical entre este punto y la recta de regresión que estamos buscando representa el error de predicción para ese jugador específico. Si elevamos al cuadrado cada una de estas desviaciones verticales, así siempre son positivas, obtenemos una función  $f(b_0, b_1)$  que representa el error total de la recta con respecto a los puntos. El objetivo es obtener los estimadores de  $b_1$  y  $b_0$  que reducen al mínimo la  $f(b_0, b_1)$ . Entonces la línea de regresión estimada tiene la ecuación  $\hat{y} = \hat{\beta}_1 x + \hat{\beta}_0$

El valor de los estimadores se obtiene con la derivada parcial de la función de error con respecto a cada una, hallando las ecuaciones normales y resolviendo el sistema de ecuaciones para  $\beta_1$ , quedando

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 * \bar{x} ; \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Para todas las características dadas los estimadores son:

$x_1 = \text{attacking\_crossing}$

$x_2 = \text{attacking\_finishing}$

$x_3 = \text{attacking\_heading\_accuracy}$

$x_4$  = attacking\_short\_passing  
 $x_5$  = attacking\_volleys  
 $x_6$  = skill\_dribbling  
 $x_7$  = skill\_curve  
 $x_8$  = skill\_fk\_accuracy  
 $x_9$  = skill\_long\_passing  
 $x_{10}$  = skill\_ball\_control  
 $x_{11}$  = movement\_acceleration  
 $x_{12}$  = movement\_sprint\_speed  
 $x_{13}$  = movement\_agility  
 $x_{14}$  = movement\_reactions  
 $x_{15}$  = movement\_balance  
 $x_{16}$  = power\_shot\_power  
 $x_{17}$  = power\_jumping  
 $x_{18}$  = power\_stamina  
 $x_{19}$  = power\_strength  
 $x_{20}$  = power\_long\_shots  
 $x_{21}$  = mentality\_aggression  
 $x_{22}$  = mentality\_interceptions  
 $x_{23}$  = mentality\_positioning  
 $x_{24}$  = mentality\_vision  
 $x_{25}$  = mentality\_penalties  
 $x_{26}$  = mentality\_composure  
 $x_{27}$  = defending\_standing\_tackle  
 $x_{28}$  = defending\_sliding\_tackle  
 $x_{29}$  = goalkeeping\_diving  
 $x_{30}$  = goalkeeping\_handling  
 $x_{31}$  = goalkeeping\_kicking  
 $x_{32}$  = goalkeeping\_positioning  
 $x_{33}$  = goalkeeping\_reflexes

	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$	$x_{10}$
--	-------	-------	-------	-------	-------	-------	-------	-------	-------	----------

$\widehat{\beta}_1$	73285.618118	63064.593415 93000135617 331	53646.953450 39999665459 618	115433.98028 55799935059 6219	78064.602137 59999896865 338	73124.576177 65999748371 542	81358.806290 38000188302 249	74313.541657 85999794024 974	104638.44507 05199997173 6223	92367.780407 09999913815 409
$\widehat{\beta}_0$	-1411095.743 12713998369 872570	-663298.0747 73820000700 65260	-558099.7634 68420016579 32997	-4551790.193 16270016133 785248	-1106168.336 94540988653 898239	-1836993.660 21140990778 803825	-1614288.201 21809002012 014389	-922822.5959 96379968710 24370	-3284717.893 87637982144 951820	-3177112.340 44871991500 258446

	$x_{11}$	$x_{12}$	$x_{13}$	$x_{14}$	$x_{15}$	$x_{16}$	$x_{17}$	$x_{18}$	$x_{19}$	$x_{20}$
$\widehat{\beta}_1$	60831.893073 12999881105 497	63286.492392 40000315476 209	69847.630342 58999687153 846	312472.75526 11000137403 6074	46960.586480 30000040307 641	135579.79982 02999879140 4068	60619.495638 82999791530 892	72776.190129 25999413710 088	59151.238456 92999748280 272	71058.022790 86000635288 656
$\widehat{\beta}_0$	-1685771.248 23908996768 295765	-1846184.539 47828989475 965500	-2198860.131 06798008084 297180	-17026454.35 89069806039 3333435	-776839.2753 98769997991 62149	-5605299.462 07770984619 855881	-1690632.058 81301988847 553730	-2330686.549 98341016471 385956	-1604810.993 19284991361 200809	-1097771.931 59305001609 027386

	$x_{21}$	$x_{22}$	$x_{23}$	$x_{24}$	$x_{25}$	$x_{26}$	$x_{27}$	$x_{28}$	$x_{29}$	$x_{30}$
$\widehat{\beta}_1$	60771.265989 84000156633 556	38846.776150 58000083081 424	66611.010396 18000504560 769	136227.95652 64699922408 9086	72567.790703 79999757278 711	188242.58163 09399961028 2481	31401.751564 90000154008 158	27193.181637 18000141670 927	-3500.462743 56999992960 482	-3276.070388 13000008303 788
$\widehat{\beta}_0$	-1147315.094 72492011263 966560	428149.89484 31399767287 0755	-1122776.763 28359008766 710758	-5108096.562 76862975209 951401	-1262098.930 56269991211 593151	-8689241.978 94736006855 964661	730662.45558 84100263938 3078	986258.89508 28999513760 2091	2282382.0824 32900089770 55550	2278005.1643 931

	$x_{31}$	$x_{32}$	$x_{33}$
$\widehat{\beta}_1$	-3969.93323905	-2891.77044992	-3000.0607193
$\widehat{\beta}_0$	2288742.54506815	2271735.10661679	2274468.22415621

Teniendo la recta de regresión para cada una ahora hay que elegir cuál es la que mejor se ajusta a los datos

Las desviaciones verticales entre los valores observados y los estimados se llaman residuos y la suma al cuadrado de estos es la desviación no explicada o *SCE*. Por otro lado se tiene la variabilidad explicada *SCR* y la suma de ambas es la variación total denotada como  $STC(S_{yy})$ . Reordenando la igualdad  $STC = SCR + SCE$  y dividiendo a ambos miembros

por la variabilidad total se obtiene la proporción de variación observada que puede ser explicada por el modelo de regresión lineal simple, llamado **coeficiente de determinación**, denotado por .

$$R^2 = 1 - \frac{SCE}{STC}$$

El coeficiente de determinación siempre es menor o igual a 1 y mayor o igual a 0. Entre más cerca de 1 se encuentre mejor es el modelo al explicar la variación de Y

Por otro lado tenemos el coeficiente de correlación lineal, denotado con  $r$ , que es la medida que podemos usar para describir que tan fuerte es la relación lineal entre las variables  $x$  e  $y$ . Si existe una relación inversa (esto es, si  $y$  disminuye al aumentar  $x$ ), entonces  $r$  tomará valores entre 0 y -1, de manera similar, si existe una relación directa, si  $y$  aumenta al aumentar  $x$ , entonces  $r$  obtendrá un valor entre 0 y 1. Se puede calcular con 3 formulas:

$$r = \frac{Cov(x, y)}{\sqrt{S_{xx}S_{yy}}} \quad r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} \quad r = \sqrt{R^2}$$

	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$	$x_{10}$
$R^2$	0.06797879	0.05863771	0.03316713	0.10868381	0.07301351	0.07249084	0.08450379	0.06304123	0.09723168	0.09027988
$r$	0.26072742	0.24215225	0.18211846	0.32967228	0.27021012	0.26924122	0.29069535	0.25108012	0.31181996	0.30046611

	$x_{11}$	$x_{12}$	$x_{13}$	$x_{14}$	$x_{15}$	$x_{16}$	$x_{17}$	$x_{18}$	$x_{19}$	$x_{20}$
$R^2$	0.03166739	0.03319463	0.04008138	0.31144334	0.01678083	0.12546648	0.01994865	0.05129204	0.02106479	0.07227973
$r$	0.17795333	0.18219393	0.20020335	0.55807109	0.12954084	0.35421248	0.14123971	0.22647745	0.14513713	0.2688489


	$x_{21}$	$x_{22}$	$x_{23}$	$x_{24}$	$x_{25}$	$x_{26}$	$x_{27}$	$x_{28}$	$x_{29}$	$x_{30}$
$R^2$	0.04198011	0.02492783	0.06442997	0.13425635	0.04967725	0.1998766	0.01734888	0.01247068	0.00014541	0.00011698

$r$	0.20489049	0.1578855	0.25383059	0.36641008	0.22288394	0.44707561	0.13171516	0.1116722	-0.01205859	-0.0108157
-----	------------	-----------	------------	------------	------------	------------	------------	-----------	-------------	------------

	$x_{31}$	$x_{32}$	$x_{33}$
$R^2$	0.00016519	9.30138042e-05	0.00011049
$r$	-0.01285274	-0.00964437	-0.01051163

Con los resultados obtenidos se puede observar que si bien ninguna tiene una correlación lineal fuerte con la propiedad que se intenta predecir, la característica más relevante y que mejor explica el valor de mercado del jugador es “movement\_reactions”, ya que tiene tanto el mayor coeficiente de determinación como el mayor coeficiente de correlación lineal

La recta de regresión lineal que podemos dibujar utilizando los estimadores que calculamos anteriormente en base a los valores de “movement\_reactions” queda como



### Test de significancia

El test de significancia sirve para evaluar si la relación entre la variable predictora y la variable de respuesta es estadísticamente significativa. Se realiza sobre la pendiente  $\beta_1$ , tomando  $H_0: \beta_1 = 0$  y  $H_1: \beta_1 \neq 0$ , y utilizando el estadístico de prueba

$$T = \frac{\hat{\beta}_1 - \theta}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} \sim t_{n-2} \text{ bajo } H_0$$

donde

$$\hat{\sigma}^2 = \frac{SCE}{n-2} \text{ y } S_{xx} = \sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}$$

Aceptar  $H_0$  es equivalente a concluir que no hay ninguna relación lineal entre  $x$  e  $y$ , por otro lado si el resultado es el contrario, implica que  $x$  tiene importancia al explicar la variabilidad de  $y$ . Además, como no se tiene un nivel de significancia  $\alpha$ , se debe usar el P-valor, que en este caso es igual a  $P(|T| > |t_0|)$ .

Reemplazando los valores nos queda

$$t_0 = \frac{312472.7552611 - 0}{\sqrt{\frac{1.79277691e + 13}{1573139.15619724}}} = 2.6131$$

Dado este valor si utilizamos la aplicación "Probability Distributions" con la distribución de Student  $n-2$  grados de libertad ( $n$  siendo 18944) el P-valor da un resultado de 0

Como  $0 < 0.05$  hay evidencia suficiente para rechazar  $H_0$  y concluir que la característica "movement\_reactions" tiene relevancia en el valor de mercado del jugador

ii)

Para este inciso hay que calcular los intervalos de confianza del 95% para los valores de  $\beta_1$  y  $\beta_0$ , es decir utilizaremos un  $\alpha = 0.05$

Para  $\beta_1$  tenemos el mismo estadístico usado para el test de significancia

$$P\left(-t_{\frac{\alpha}{2}, n-2} < \frac{\hat{\beta}_1 - \theta}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}} < t_{\frac{\alpha}{2}, n-2}\right)$$

y el intervalo es

$$\left[ \hat{\beta}_1 - t_{\frac{\alpha}{2}, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} ; \hat{\beta}_1 + t_{\frac{\alpha}{2}, n-2} \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}} \right]$$

$$\left[ 312472.7552 - 1.9604 \sqrt{\frac{1.79277691e + 13}{1573139.15619724}} ; 312472.7552 + 1.9604 \sqrt{\frac{1.79277691e + 13}{1573139.15619724}} \right]$$

$$[305,851.32 ; 319,094.20]$$

Para  $\beta_0$  tenemos el estadístico

$$\left[ \hat{\beta}_0 - t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} ; \hat{\beta}_0 + t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left( \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)} \right]$$

$$\left[ -17026454.35890698 - 1.9604 \sqrt{1.79277691e + 13 \left( \frac{1}{18944} + \frac{61.60942778716216^2}{1573139.15619724} \right)} ; -17026454.35890698 + 1.9604 \sqrt{1.79277691e + 13 \left( \frac{1}{18944} + \frac{61.60942778716216^2}{1573139.15619724} \right)} \right]$$

$$[-17438535.04157005; -16614373.6762439]$$

iii)

Para hallar la proporción de veces que el valor de mercado supera la incertidumbre de predicción comparada con la respuesta media del valor de mercado para una característica fija, hay que calcular haciendo el error del intervalo para la media dividido el error del intervalo de predicción

Los intervalos de confianza tienen forma  $[\hat{\theta} - \varepsilon; \hat{\theta} + \varepsilon]$ , donde  $\hat{\theta}$  es el estimador y  $\varepsilon$  es el error. El cociente de ambos errores nos queda como

$$\frac{t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left( 1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}}{t_{\frac{\alpha}{2}, n-2} \sqrt{\hat{\sigma}^2 \left( \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}} \right)}}$$

El ancho del intervalo de confianza depende de  $(x^* - \bar{x})$ , por lo tanto este será mínimo cuando el valor de  $x^*$  se acerque al valor de  $\bar{x}$  y crece a medida que  $x^*$  se aleje del promedio. Como lo que queremos es un ancho mínimo, igualamos  $x^*$  a  $\bar{x}$  la resta nos queda igual a cero, anulando todo su término. Haciendo eso y cancelando de ambas partes ya que se usa el mismo nivel de confianza, queda

$$\frac{\sqrt{\hat{\sigma}^2 \left( 1 + \frac{1}{n} \right)}}{\sqrt{\hat{\sigma}^2 \frac{1}{n}}} = \frac{\sqrt{\hat{\sigma}^2} \sqrt{\left( 1 + \frac{1}{n} \right)}}{\sqrt{\hat{\sigma}^2} \sqrt{\frac{1}{n}}} = \frac{\sqrt{\left( 1 + \frac{1}{n} \right)}}{\sqrt{\frac{1}{n}}} = \frac{\sqrt{\frac{1}{n}} \sqrt{n+1}}{\sqrt{\frac{1}{n}}} = \sqrt{n+1}$$

reemplazando n en la fórmula



$$\sqrt{18944 + 1} = \sqrt{18945} = 137.64083$$

Con lo que concluimos que el valor de mercado supera la incertidumbre de predicción algo más de 137 veces más frecuentemente de lo que supera a la respuesta media, para la característica “movement reactions”.

## Parte 2: Ecuación de predicción del valor de mercado

Para esta sección definiremos las siguientes variables relevantes, en base a las cuales realizaremos la regresión lineal múltiple  $y = b_0 + b_1x_1 + b_2x_2 + b_3x_3$ .

$y = \text{value\_eur}$

$x_1 = \text{movement\_reactions}$

$x_2 = \text{mentality\_composure}$

$x_3 = \text{mentality\_vision}$

Con el fin de calcular los coeficientes  $b_0, b_1, b_2$ , y  $b_3$  mediante el método de mínimos cuadrados, buscaremos minimizar la función:

$$f(b_0, b_1, b_2, b_3) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Para ello desarrollamos  $\hat{y}$ , calculamos sus 4 derivadas parciales, las igualamos a 0, y pasando algunos términos obtenemos el siguiente sistema de ecuaciones:

$$\sum y_i = nb_0 + b_1 \sum x_{1i} + b_2 \sum x_{2i} + b_3 \sum x_{3i}$$

$$\sum y_i x_{1i} = b_0 \sum x_{1i} + b_1 \sum x_{1i} x_{1i} + b_2 \sum x_{1i} x_{2i} + b_3 \sum x_{1i} x_{3i}$$

$$\sum y_i x_{2i} = b_0 \sum x_{2i} + b_1 \sum x_{2i} x_{1i} + b_2 \sum x_{2i} x_{2i} + b_3 \sum x_{2i} x_{3i}$$

$$\sum y_i x_{3i} = b_0 \sum x_{3i} + b_1 \sum x_{3i} x_{1i} + b_2 \sum x_{3i} x_{2i} + b_3 \sum x_{3i} x_{3i}$$

Reemplazando:

$$42146863000 = 18944b_0 + b_1 1167129 + b_2 1098348 + b_3 1019722$$

$$3088207239000 = b_0 1167129 + b_1 73479289 + b_2 69109904 + b_3 64055331$$

$$2967287763000 = b_0 1098348 + b_1 69109904 + b_2 66462642 + b_3 61223055$$

$$2754741110000 = b_0 1019722 + b_1 64055331 + b_2 61223055 + b_3 58457748$$

Luego sabemos que podemos expresar esta igualdad como una multiplicación de matrices:

$$\begin{bmatrix} 18944 & 1167129 & 1098348 & 1019722 \\ 1167129 & 73479289 & 69109904 & 64055331 \\ 1098348 & 69109904 & 66462642 & 61223055 \\ 1019722 & 64055331 & 61223055 & 58457748 \end{bmatrix} \cdot \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} 42146863000 \\ 3088207239000 \\ 2967287763000 \\ 2754741110000 \end{bmatrix}$$

$X \qquad \qquad \qquad b \qquad \qquad \qquad Y$

Siendo que la matriz  $X$  es siempre cuadrada por definición, con  $k + 1$  filas y  $k + 1$  columnas, siendo  $k$  el número de variables que influyen a  $Y$ , este sistema es fácilmente resoluble calculando la inversa de la matriz  $X$ ,  $X^{-1}$ , y luego multiplicando de ambos lados por esta inversa. El nuevo sistema de matrices dicta que  $X^{-1}Xb = X^{-1}Y$ . Sabemos también que  $XX^{-1}$  es igual a la matriz identidad de tamaño  $k + 1$ , y por definición de la identidad hace de neutro en la multiplicación con  $b$ .

Tras simplificar, la última iteración de nuestro sistema de matrices declara la igualdad entre  $b$  y  $X^{-1}Y$ , que son dos matrices de valores conocidos:

$$\begin{bmatrix} 0.002478 & -0.00003779 & 0.0000005186 & -0.000002353 \\ -0.00003779 & 0.000001225 & -0.0000005683 & -0.00000008802 \\ 0.0000005186 & -0.0000005683 & 0.000000911 & -0.0000003403 \\ -0.000002353 & -0.00000008802 & -0.0000003403 & 0.0000005111 \end{bmatrix} \cdot \begin{bmatrix} 42146863000 \\ 3088207239000 \\ 2967287763000 \\ 2754741110000 \end{bmatrix} = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

$X \qquad \qquad \qquad Y \qquad \qquad \qquad b$

Resolviendo obtenemos los coeficientes:

$$\begin{bmatrix} -17227131.92 \\ 261885.52 \\ 32244.70 \\ 26897.10 \end{bmatrix}_{XY} = \begin{bmatrix} b0 \\ b1 \\ b2 \\ b3 \end{bmatrix}_b$$

Con el sistema de matrices resuelto, podemos trazar la recta de regresión lineal de value\_eur en base a nuestras tres estadísticas de la siguiente forma.

$$\hat{y} = -17227131.92 + 261885.52x_1 + 32244.70x_2 + 26897.10x_3$$

i) Teniendo calculados los coeficientes  $b0$  a  $b3$ , buscaremos obtener los coeficientes de determinación y la correlación del modelo.

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Calculamos el SCE, o suma de cuadrados de error, utilizando software para procesar los datos del archivo players.csv, obteniendo el resultado  $SCE = 3.3449575127625146 \times 10^{17}$ .

Acto seguido calculamos el STC, definido como  $\sum_{i=1}^n (y_i - \bar{y})^2$ , que representa la desviación total de la media, y cuyo resultado da  $4.931878872786333 \times 10^{17}$ .

Finalmente, calculamos  $R^2$  calculando la diferencia entre 1 y el cociente de SCE sobre STC.

$$R^2 = 1 - \frac{SCE}{STC} = 1 - \frac{3.3449575127625146 \times 10^{17}}{4.931878872786333 \times 10^{17}} = 0.321768113320931$$

$$r = \sqrt{R^2} = \sqrt{0.32176811332093} = 0.5672460782772597$$

Para la raíz de  $R^2$  tomamos solo la raíz positiva, ya que sabiendo que los coeficientes de todas las variables involucradas en la regresión lineal múltiple son positivos, podemos afirmar que la correlación que haya será positiva también, puesto que en este esquema cada punto adicional puesto en cualquier  $x_k$  agrega una fracción positiva de su valor a  $y$ .

Interpretando los coeficientes podemos afirmar que si bien las predicciones no son despreciables, ya que se pudo predecir aproximadamente el 32% de la variación del precio del jugador con tan solo 3 de las múltiples variables involucradas, este sigue sin ser un buen modelo de predicción. El coeficiente de determinación se halla demasiado lejano a la unidad como para que podamos acercarnos a realmente predecir el precio de jugadores contando con tan poca información.

Del lado de  $r$  podemos afirmar que la correlación entre nuestras variables y el valor del jugador es positiva, es decir que esperamos que estas cantidades crezcan juntas, pero al ser un valor tan lejano

a la unidad, no podemos esperar demasiada consistencia entre sus aumentos, y podría crecer significativamente sin que esto implique que los valores de nuestras variables estén aumentando, y lo reverso también es válido.

Finalmente, y si bien no es pedido por el inciso, consideramos importante recalcar que este modelo busca descubrir correlación, y no causalidad, y que supondría un salto lógico suponer que sí se halló una correlación fuerte entre una o varias características y el precio de un jugador, aumentar dichas características aumentaría también el precio. Podrían haber muchas explicaciones de porque estas variables crecen, o decrecen, juntas, podría ser que el precio determine las estadísticas, y no las estadísticas al precio, o que tanto las estadísticas como el precio sean causadas por algún factor externo que no está siendo tenido en cuenta.

ii) Si bien el método es distinto, y los coeficientes no son idénticos a los obtenidos mediante la técnica de mínimos cuadrados, los resultados por descenso de gradiente son ampliamente similares:

$$b_0 = -17227131.44735364$$

$$b_1 = 261885.51154327$$

$$b_2 = 32244.70231416$$

$$b_3 = 26897.09727634$$

Los parámetros utilizados para esta instancia de descenso de gradiente fueron  $\alpha = 0.00001$ , tolerancia = 0.000001, punto de inicio = [0,0,0,0], e iteraciones = 44558731. Lamentablemente, por la magnitud de datos a procesar, no fue posible procesar todos los datos en una única ejecución del algoritmo de descenso de gradiente, para solventar esta complicación, los datos fueron calculados usando no uno sino dos descensos de gradiente, el primero descendió hasta el punto [-17212328.15788638, 261659.65930791, 32247.8544781, 26883.04967699], desde el cual se continuó el descenso con los mismos parámetros antes mencionados, a excepción de tener ahora  $\alpha = 0.0001$ , y contar con el actualizado punto de inicio. El conteo de iteraciones toma en cuenta las iteraciones de ambos descensos, y plantea su suma.

Finalmente, presentamos el listado de las últimas iteraciones del segundo descenso de gradiente, con paso de 0.0001:

[-17227131.44734863, 261885.51154319, 32244.70231416, 26897.09727633]

[-17227131.44734963, 261885.51154321, 32244.70231416, 26897.09727633]

[-17227131.44735064, 261885.51154322, 32244.70231416, 26897.09727633]

[-17227131.44735164, 261885.51154324, 32244.70231416, 26897.09727634]

[-17227131.44735264, 261885.51154325, 32244.70231416, 26897.09727634]

[-17227131.44735364, 261885.51154327, 32244.70231416, 26897.09727634]

iii) Los algoritmos de descenso de gradiente son varios, hay multitud de implementaciones distintas, y no todas comparten condición de corte, sin embargo, la condición de corte más universal de este algoritmo es la de detención por gradiente pequeño, esto es, cuando el algoritmo se detiene

porque detecta que la actualización de las variables del gradiente están cambiando en magnitudes muy pequeñas. Al detectar el algoritmo que las variables están cambiando muy poco asume que se hallan cerca de su valor mínimo, y detiene la búsqueda, mas esta es una falla del algoritmo, pues podría ser el caso que la velocidad de actualización se reduzca por haber llegado a un mínimo local no global, o a un punto silla. Cuando el algoritmo se detiene por alguno de esos motivos, el algoritmo falla en su misión de obtener los valores que minimizan la función provista.

Lamentablemente no tenemos la formación para ofrecer una reforma de valor al algoritmo, pero creemos que la implementación de Descenso de Gradiente con Momento podría conformar una buena modificación al original para arreglar la problemática mencionada. Este tipo de Descenso de Gradiente registra una dirección promedio en base a iteraciones anteriores del algoritmo, y así evita depender exclusivamente del gradiente correspondiente al instante actual. El momento acumulado le facilita a esta versión del Descenso de Gradiente atravesar algunos puntos silla, mínimos locales, y “valles” largos con valores bajos.

Si bien esta solución no es perfecta, desconocemos una que lo sea, y al cambiar la forma de cálculo del gradiente, que es parte de cómo el algoritmo juzga su condición de corte, por proxy modifica su condición de corte, haciéndola menos propensa a fallar.

### **Parte 3: Comportamiento del método de descenso por gradiente**

Como fue destacado en el inciso iii) de la Parte 2, no, lamentablemente no siempre converge al mínimo de la función, y esto se debe a que la condición de corte depende de una ralentización de la velocidad descenso, y esta puede ser causada por puntos silla y mínimos locales, que pueden llegar a engañar a la función, la cual se detendrá como si hubiera llegado al mínimo global, aunque en realidad sean otras las causas de la ralentización de la actualización del gradiente.

#### Contraejemplo


Consideremos la función  $f(x) = ((x + 2)^2 - 3)^2 + x + 2$ . Esta función tiene múltiples mínimos locales y un mínimo global. Si inicializamos el descenso por gradiente en un punto cercano a un mínimo local pero lejos del mínimo global, el algoritmo puede quedarse atrapado en ese mínimo local. Esto se debe a que, conforme se acerca a un mínimo local, el gradiente tiende a reducirse y las actualizaciones se hacen más pequeñas, llevando al algoritmo a detenerse prematuramente.

Además, con una tasa de aprendizaje inadecuada (demasiado baja o demasiado alta), el algoritmo puede reducir su velocidad de descenso y confundir un mínimo local con el mínimo global. Esto ilustra uno de los principales problemas del método de descenso por gradiente.

Decidimos utilizar un contraejemplo con una función sencilla del formato  $y = f(x)$  por motivos de simplicidad, y para resolverla utilizamos otro programa de descenso de gradiente, distinto al utilizado para los cálculos de la parte dos. La motivación detrás de esto es que el primer código estaba diseñado para regresión lineal múltiple, y siempre admitía al intercepto como valor a calcular. Dado que aquí queremos calcular un solo  $x$ , consideramos apropiado el uso de un algoritmo modificado, sin embargo consideramos esencial enfatizar que ambos algoritmos son algoritmos de Descenso de Gradiente, comparten condición de corte, utilizan el concepto de salto, y

actualizan sus mínimos estimados en base a la dirección y velocidad de descenso, es decir, funcionan de forma análoga, más allá de que estimen el gradiente de forma distinta, y todo lo demostrado bajo este ejemplo usando este algoritmo aplica al descenso de gradiente en general, ya que respecta a la condición de corte del mismo, que es universal.

Visualización de la función, con su mínimo estimado:



Parámetros y resultados de ejecución:  $\alpha = 0.001$ , tolerancia = 0.0001, valor de inicio = 0, número de iteraciones = 485, x estimado = -0.31121975811049024.

Últimas ejecuciones del algoritmo:

-0.31121900491507076  
-0.3112191199030829  
-0.31121923233562754  
-0.31121934226949743  
-0.311219449760223  
-0.3112195548621005  
-0.311219657628219  
-0.31121975811049024